

自监督预训练可以提高 DQN 样本效率吗

陈嘉诚 张礼贤 刘一非 谭泽宇

深圳河套学院

2026 年 6 月 2 日

研究背景与问题

核心矛盾

现实中 RL Agent 看不到真实状态，只能通过高维传感器观测，导致样本效率急剧下降。


研究问题

- ① 观测维度 M 如何影响 DQN 样本效率？
- ② 自监督预训练 (SSL) 能否缓解维度灾难？

方法：可控 8×8 GridWorld $\rightarrow$ MLP 模拟不可逆传感器 $\rightarrow$ 系统比较三条管线 (SSL $\rightarrow$ DQN / DQN-only / Identity)

实验框架：三条管线

三种观测管线对比示意图




核心结果：样本效率

管线	$M=128$	$M=256$	$M=512$	$M=1024$
SSL→DQN	250	280	180	220
DQN-only	160	180	530	840

Identity: 250 ep, 100% SR


关键发现

- ▶ $M=1024$: SSL→DQN 是 DQN-only 的 **3.8x**
- ▶ DQN-only $M=1024$ 仅 40% 最终成功率
- ▶ SSL→DQN 在所有 M 下保持稳定
- ▶ SSL→DQN 在低维度下略逊于 DQN-only (为什么呢)



学习曲线

DQN Learning Curves: Success Rate vs Episode



M=128

DQN-only 最快收敛, SSL
轻微开销



M=512

DQN-only 开始不稳定,
方差增大

M=1024

DQN-only 几乎失败,
SSL→DQN 稳定保持

进一步讨论：潜在维度的可压缩性



原始状态空间

RL 决策真正需要的状态空间

进一步讨论：潜在维度的可压缩性

观察：64 维可能不是下限

GridWorld 中许多位置存在状态简并。

- ▶ 例如：棋盘中间大片区域的最优动作都是「向右 + 向下」组合

SSL 学习到的结构 vs RL 需要的结构

- ▶ **Autoencoder** 学的是观测重建：保留 M 维观测的所有变化，包括与任务无关的噪声
- ▶ **RL** 需要的是决策相关的表示：不同状态只要最优动作相同，就可以映射到同一点
- ▶ 当前 SSL 目标（重建 $\mathbf{o}$ ）与 RL 目标（最大化回报）存在不一致

核心问题

如何控制 SSL 的学习目标，使其学到的潜在空间对齐 **RL** 的任务结构，而非单纯重建观测？

这是从「无监督表示学习」走向「任务感知表示学习」的关键一步。

- ① 维度灾难被验证：DQN-only 在 $M=1024$ 时崩溃（40% SR，44 步路径）
- ② **SSL** 有效缓解：SSL→DQN 保持 100% SR + 最优路径，与 M 无关
- ③ 交叉点存在：约 $M \approx 400$ 处 SSL→DQN 超越 DQN-only
- ④ 潜在维度可进一步压缩：RL 状态简并意味着 64 维不是下限，如何让 SSL 学 RL 相关结构是未来方向

谢谢！欢迎提问。